




제조 설비 정비 예측을 위한 데이터 전처리 파이프라인

기계학습 모델의 성능을 결정하는 7단계 데이터 정제 및 변환 공정 설계도


불규칙한 현장 데이터를 예측 모델의 정밀한 연료로 변환합니다

Industrial Concrete Gray

중복된 ID


문자가 섞인
숫자

서로 다른
두 개의 기준표



Before & After

[전처리 파이프라인]



Technical Mint Green

병합 완료

결측치 제거

스케일링 및
인코딩 완료

머신러닝
입력 대기

				A	B
				1	2
				0.06	0.33
				0.02	0.07
				0.42	0.13
				0.36	0.07
				0.06	0.43
				0.35	0.34
				0.30	0.85
				0.32	0.30
				0.28	0.29
				...	...

목표: 설비 기준표를 정제하고 센서 기준표를 결합하여,
정비 필요 여부(maintenance_required)를 예측할 최적화된 입력표 완성.

데이터 설계도: 3개의 원본 파일과 각 요소의 역할 구조

기본 정보 (Main Data)

manufacturing_equipment.csv

- 크기: 243행 × 16열
- 역할: 대상 설비의 기본 정보
- 특징 1: equipment_id에 중복 중복 3행 포함
- 특징 2: rated_cycle_sec에 문자 혼재

타겟 변수: maintenance_required

보조 기준표 (Extra Data)

manufacturing_specs.csv


- 크기: 240행 × 6열
- 역할: 센서 및 진동 기준치
- 특징: equipment_id를 기준으로 기본 정보와 1:1 결합

신규 대상 (New Data)

manufacturing_equipment_new.csv


- 크기: 40행 × 15열
- 역할: 실전 추론용 처음 보는 대상
- 특징: 정답(타겟 변수)이 존재하지 않음

머신러닝을 위한 7단계 디지털 조립 라인




품질 관리: 불량 데이터를 걸러내고 빈 공간을 메웁니다 (Step 1 & 2)

1. 중복 제거 (Deduplication)




중복된 equipment_id 3건 제거
(keep='first')

2. 문자열 표준화 (String Formatting)



plant 열의
대소문자 및 공백 통일


3. 결측치 처리 (Imputation)



rated_cycle_sec 등의
강제 숫자 변환(coerce) 후,
빈칸을 중앙값(Median)으로 대체

무결성 검증 통과: `assert len(clean) == 240` 및 `assert clean['equipment_id'].is_unique`


컴포넌트 조립: 1:1 무결성 검증을 통한 데이터 병합 (Step 3)



✓ `assert len(joined) == 240` (결측치 0 확인)

시간의 정량화: 날짜 데이터를 머신러닝이 이해할 수 있는 '경과일'로 변환 (Step 4)

고정된 기준일: 2026-09-01
(Reference Date)




days_since_inspection
239
386
40


변환 실패 대한 날짜(NaT)는 다시
중앙값(Median)으로 안전하게 대체 처리됨.



훈련과 검증의 분리: 정답의 비율을 완벽하게 유지하는 계층적 분할 (Step 5)



이중 트랙 전처리: 데이터의 성격에 맞춘 맞춤형 자동화 라인 (Step 6A)




데이터 변환 메커니즘 비교: 숫자형 vs 범주형 (Step 6B)

[분류 기준]	[숫자형 데이터 (Numeric Track)]	[범주형 데이터 (Categorical Track)]
결측치 처리 (Imputation)	중앙값(Median) 채우기. 극단적인 이상치의 영향을 배제하여 안정적인 기준점 확보.	최빈값(Most Frequent) 채우기. 해당 카테고리에서 가장 흔하게 등장하는 정상 상태값 적용.
변환 방식 (Scaling & Encoding)	StandardScaler 사용. 평균을 0, 표준편차를 1로 맞추어 단위가 다른 센서 값들의 스케일 통일.	OneHotEncoder 사용. 문자를 0과 1로 구성된 다수의 독립적인 이진열(Binary Columns)로 분해.
예외 처리 (Exception Handling)	(숫자의 본질적 연속성으로 인해 특별한 예외 처리 불필요)	handle_unknown='ignore'. 실전(Test)에서 처음 보는 장비 모델이 등장해도 오류 없이 0으로 무시.




머신러닝 파이프라인의 황금률: 학습과 적용의 엄격한 분리

fit_transform() 메서드



- 적용 대상: 오직 Train Data (훈련 셋)에만 사용
- 동작 원리: 데이터를 보고 기준(평균, 최빈값 등)을 새롭게 학습(fit)한 뒤, 그 기준으로 데이터를 변환(transform).
- 공장 비유: 제품 규격에 맞춰 새로운 금형 틀을 처음 제작하고 생산하는 과정.

transform() 메서드




- 적용 대상: Test Data 및 실전 New Data에 사용
- 동작 원리: 새롭게 학습하지 않음. Train에서 이미 완성된 기준을 그대로 적용만 함.
- 공장 비유: 이미 완성된 금형 틀에 새로운 재료를 통과시켜 찍어내는 과정.



경고 : Test 데이터에 fit을 사용하면 모델이 미래의 정답을 미리 훑쳐보는 데이터 누수(Data Leakage)가 발생하여 예측 모델이 붕괴됩니다.

실전 생산 라인: 처음 보는 40개의 신규 데이터 추론 준비 (Step 7)



완벽하게 변환된 40행의 최종 입력 배열. AI 모델 추론 준비 완료.

무결성 검증: 침묵하는 시스템이 곧 완벽한 파이프라인을 의미합니다

자동화된 assert 문을 통한 3단계 무결성 보증



◉ 형태 무결성 (Shape Integrity)

```
assert X_train.shape == (192, 12)  
assert X_test.shape == (48, 12)
```

지정된 80/20 데이터 분할 비율이 단 한 줄의 누락 없이 정확하게 수행되었음을 증명합니다.



◉ 특성 정렬 무결성 (Feature Alignment)

```
assert train_processed.shape[1] == test_processed.shape[1]
```

OneHotEncoder 통과 후에도 Train과 Test 데이터셋의 컬럼 개수와 순서가 완벽히 일치함을 증명합니다.



◉ 결측치 제로 (No Missing Values)

```
assert np.isnan(train_processed).sum() == 0
```


모든 결측치가 설계된 규칙(중앙값, 최빈값)에 의해 100% 완벽하게 채워졌음을 증명합니다.



결과: 모든 테스트를 오류 없이(Silent) 통과. 기계적 결함 0%.


최종 산출물: 기계학습을 위한 완벽한 매트릭스의 완성

원본: 분절되고 불안정한 현장 데이터



train_processed
(192행, 순수 숫자형)

test_processed
(48행, 순수 숫자형)



new_processed
(40행, 순수 숫자형)


test_processed
(40행, 순수 숫자형)



최종 저장소 → [outputs/manufacturing_master_clean.csv](#)

최종 제출 전 필수 점검표

- ✓ 모든 FILL_ME 템플릿 코드 삭제 완료
- ✓ 모든 assert 검증 코드가 오류 없이 조용히 통과함
- ✓ 실행 결과가 렌더링된 주피터 노트북 파일(.ipynb) 자체 저장 완료
- ✓ outputs 폴더에 생성된 최종 정제 CSV 파일 확인 완료
- ✓ Markdown 셀에 '가장 헛갈렸던 단계'와 '해결 방법' 3문장 작성 완료

 데이터 정제소 가동 완료. 데이터는 이제 예측 모델이 될 완벽한 준비를 마쳤습니다.