


가맹점 위험도 예측을 위한 데이터 파이프라인 구축

[FINANCE_MERCHANTS] 결제 데이터
정제 및 머신러닝 모델 도입을 위한
엔드투엔드(End-to-End) 설계도

목표 (Objective)	원본 가맹점 데이터와 리스크 운영 규칙을 결합하여, 수동 검토 필요 여부(manual_review_required)를 예측하는 머신러닝 입력표 완성.
핵심 프로세스 (Core Process)	데이터 정제 → 결합 → 시계열 피처 엔지니어링 → 전처리 파이프라인 구축 → 신규 데이터 검증




파이프라인의 핵심 자산: 데이터 생태계 매트릭스

Historical Base (과거 기준표)

finance_merchants.csv

243행 × 16열 (중복 3행 포함)

대상 가맹점의 기본 정보 및 과거 실적 기준 데이터
(예: monthly_sales_10k_krw, avg_ticket_krw).




Business Rules (운영 규칙표)

finance_risk_rules.csv

240행 × 6열

각 대상에 부여된 추가 위험 관리 기준
(예: daily_limit_10k_krw, cross_border_allowed).




Future Stream (신규 유입 데이터)


finance_merchants_new.csv

40행 × 15열

처음 관측되는 신규 가맹점. 정답 레이블이 없는
실전 배포(Production) 환경의 테스트 베드.




Phase 1: 데이터 정제 및 무결성 확보



검증 완료: 식별자
고유성(is_unique) 확보,
총 240행 정제.

Phase 2: 리스크 규칙 결합과 엔티티 통합

merchant_id



결합 방식

Left Merge (기준표 유지).

무결성 검증 (Failsafe)

validate='one_to_one' 매개변수를 통해 양쪽 표에서 merchant_id가 정확히 한 번씩만 매칭됨을 강제 시스템 검증.

풍부해진 특성

단순 가맹점 정보에 daily_limit_10k_krw, refund_alert_rate 등 리스크 운영 지표가 누락 없이(isna().sum() == 0) 완벽히 결합됨.

피처 엔지니어링: 시간의 구조화 (The Dimension of Time)



STEP 1: 날짜 변환

단순 문자열 날짜를 연산 가능한 datetime 객체로 변환 (변환 실패 시 NaT 처리).

STEP 2: 기준점 고정

시뮬레이션의 일관성을 위해 시스템 기준일을 2026-09-01로 고정.

STEP 3: 거리 계산


(기준일 - KYC 리뷰일)을 계산하여 '경과일(Days)'이라는 수치형 피처로 변환.

STEP 4: 보정


변환되지 못한 결측치(NaT)는 전체 경과일의 중앙값으로 안전하게 채움.

Phase 3: 모델 검증을 위한 데이터 분할 및 계층화

Stage 1



Stage 2




Key Concept:
Stratification (계층화)



stratify=y

단순 무작위 추출이 아닌, 훈련용과 테스트용 데이터 모두에서 manual_review_required의 True/False 비율이 현실 세계와 동일하게 유지되도록 강제함.

전처리 엔진 설계 (The Preprocessing Architecture)



머신러닝의 철칙: 데이터 누수(Data Leakage) 차단

Train Data (192 rows)



fit_transform

모델이 훈련 데이터의 통계적 기준(중앙값, 표준편차 등)을 능동적으로 학습(fit)하고, 동시에 변환(transform)을 수행합니다.

Test Data (48 rows)




transform (Only)

절대 새로운 데이터의 통계를 훑쳐보지 않습니다. 훈련 단계에서 확정되어 동결된 규칙(Frozen rules)만을 엄격하게 적용하여 변환(transform)합니다.

핵심 통찰: 테스트 데이터는 완벽히 통제된 미지의 영역이어야 합니다.
훈련 단계에서 학습한 전처리 기준만을 엄격하게 적용하여 모델의 실제 예측력을 검증합니다.

Phase 4: 실전 배포 (Production Deployment)



1. 동일한 정제 로직 적용

지역명 통일, 날짜 변환(2026-09-01 기준
경과일 산출), 문자열 수치화.


2. 규칙 동결 (Frozen State)

fit을 절대 호출하지 않고, 기존에 생성된 `preprocessor.transform()`
단일 메서드만 사용하여 40행의 데이터를 변환.

3. 검증

기존 훈련 데이터와 완벽히 동일한
열(Feature) 구조로 출력됨 보장.

브릿지 로직: 과거 데이터 기반의 결측치 주입



The Business Challenge

신규 가맹점(40행)에는 아직 `finance_risk_rules`의
리스크 지표가 존재하지 않음.
모델을 통과시키려면 빈 열을 채워야 함.

The Solution

가맹점을 버리지 않고 과거의 기준(Baseline)을 차용.
- 수치형 빈 열: 기존 결합표의 중앙값(Median) 주입.
- 범주형 빈 열: 기존 결합표의 최빈값(Mode) 주입.

결과

운영 규칙이 없는 신규 가맹점도
안전하게 ML 파이프라인을
통과할 수 있는 연속성 확보.

최종 산출물 및 파이프라인 검증 완료



outputs/finance_merchant_master_clean.csv

- ✓ [SYSTEM] 소스 코드 내 모든 FILL_ME 템플릿 제거 및 자가 작성 완료.
- ✓ [TEST] 모든 검증 코드(assert) 무결점 통과 (Silent Pass).
- ✓ [SAVE] 실행 결과가 보존된 최종 Notebook 파일 저장.
- ✓ [EXPORT] 정제된 최종 마스터 데이터 CSV 추출 완료.
- ✓ [REVIEW] 회고록 작성 완료 (가장 헛갈렸던 단계와 해결 방법에 대한 3문장 요약).

최종 요약: 불규칙하고 파편화되어 있던 원본 가맹점 데이터가, 즉시 머신러닝 학습 및 신규 데이터 예측에 투입될 수 있는 강력한 '무결점 매트릭스'로 성공적으로 전환되었습니다.