


Week 2: Finance Data Architecture



금융 데이터 엔지니어링 파이프라인 구축


파편화된 거래 로그에서 모델 예측 및 API 서비스까지: 아키텍처 요약

Data Processing

Scikit-learn Pipeline

FastAPI

The Synthesis Arc: 파이프라인 전체 조감도



우리의 목표는 7,200건의 단순 거래 기록을 240개 가맹점의 행동 프로필로 압축하여, 다음 주차의 모니터링 시스템을 위한 완벽한 재료를 만드는 것입니다.

Source Entities: 입력 데이터의 이중성


동적 데이터 (Action)



transaction_batch_01.csv 등 12개 파일
총 7,200행 (각 600행 x 11열)

발생 시점, 금액, 승인 여부 등
시시각각 변화하는 행동(Action)

정적 데이터 (Profile)




merchant_master_reference.csv
1개 파일 / 총 240행 x 16열

지역, 산업군, KYC 상태 등
변하지 않는 속성(Profile)


파이프라인의 핵심은 '시계열 행동 로그'를 '정적 주체 정보'에
결합할 수 있는 형태로 요약하는 것입니다.

Step 1. Ingestion: 12개의 조각을 하나의 흐름으로




데이터를 단순히 합치는 것에 그치지 않고, source_file 열을 추가하여 데이터의 출처(Lineage)를 끝까지 추적합니다.

Step 2. Reshaping: 데이터 형태와 의미의 변환




전체 데이터를 처리하기 전,
4개 ID × 7일의 소규모
샘플링을 통해
pivot_table과 melt가
차원을 어떻게 재구성하는지
검증합니다.

Step 3. Aggregation: 30일의 이력을 하나의 프로필로




데이터를 버리는 것이 아닙니다. 7,200행의 단순 '이력'을 240개 가맹점의 의미 있는 '행동 패턴(Feature)'으로 압축하는 차원 축소 과정입니다.

Step 4. The Grand Merge: 완전한 데이터셋의 탄생



변하지 않는 주체 정보(Master)와 최근 30일의 활동 정보(Summary)가 결합되어, ML 모델과 API가 즉시 읽을 수 있는 하나의 완벽한 행(Row)을 구성합니다.

Step 5. Preprocessing: 머신러닝을 위한 수학적 변환




결측치와 문자열을 순수한 숫자 행렬로 변환하는 일관된 규칙(preprocessor.joblib)을 생성합니다.
이는 3주차에 동일한 구조를 재현하는 핵심 코어입니다.

Format Matrix: 아키텍처 관점의 최적화된 아웃풋 전략

포맷 (Format)	보존력 (Data Types)	속도/압축률 (Performance)	파이프라인 활용처 (Use Case)
CSV 	낮음 (텍스트 기반)	보통	DB 적재, Streamlit 시각화, 범용 호환성
Parquet 	완벽 (스키마 보존)	매우 높음 (빅데이터 최적화)	대용량 분산 처리, 백업 및 ML 재학습
JSON 	중간 (구조화 용이)	낮음 (용량 큼)	FastAPI를 통한 프론트엔드/API 통신 (list[dict])


파이프라인의 목적지에 따라 데이터의 형태도 달라져야 합니다. Parquet은 파이프라인 내부의 강력한 성능을, CSV/JSON은 외부 시스템과의 유연한 연결을 담당합니다.

Extension. API Serving : 데이터를 세상과 연결하다



로컬 디스크에 멈춰있는 데이터가 아닌,
다른 시스템(프론트엔드, 대시보드)과 실시간으로
통신할 수 있는 ‘살아있는 엔드포인트’의 구축.

The Synthesis: 3주차 시스템을 위한 견고한 토대



성공적인 데이터 파이프라인 구축이 완료되었습니다. 이제 이 정제된 자산을 바탕으로, 본격적인 금융 모니터링 애플리케이션(Week 3)의 구축이 시작됩니다.